

POS-GRADUAÇÃO - MBA Data Science em IA

Trabalho de Análise Exploratória de Dados PD

AUTHOR

Alan C. Echer

PUBLISHED

Abril 13, 2026

1 Publicação

Este projeto está disponível no github: <https://github.com/echer/26E1-infnet-trabalho-pd-analise-exploratoria-de-dados.git>

Esta disponível também no RPUB: <https://rpubs.com/alanecher/1420896>

2 Escolha da Base de Dados

A base escolhida foi o dataset de Detecção de Dengue (dados clínicos) - Disponível no kaggle:

<https://www.kaggle.com/datasets/aravind3505/dengue-detection-dataset-clinical-data>



Imagem dataset Dengue


ARAVIND3505 · UPDATED 21 DAYS AGO

12
Code
Download

Dengue Detection Dataset (Clinical Data)

Clinical blood parameters dataset for dengue disease prediction



Data Card
Code (3)
Discussion (0)
Suggestions (0)

About Dataset


Overview

This dataset contains clinical blood parameters used for the detection of dengue disease. It includes key hematological features commonly analyzed in medical diagnostics and can be used for building machine learning models for disease prediction.


Dataset Description

The dataset consists of patient-level clinical data, including blood test results such as hemoglobin levels, white blood cell count, platelet count, and other related parameters. These features are critical indicators in identifying dengue infection.

Usability
10.00

License
CC0: Public Domain

Expected update frequency
Annually

Tags
Classification

Motivo da escolha: Possui variáveis numéricas, dados faltantes, permite análise entre variáveis.

Resultados esperados: Identificar relações entre variáveis, analisar distribuição dos dados.

3 Pacotes

```
library(summarytools)
library(tidyverse)
library(GGally)
library(mice)
library(ggpubr)
library(shiny)
```

4 Carregamento da Base de Dados

```
dados <- read.csv("data/dataset.csv")
#View(dados)
```

```
summary(dados)
```

age	gender	hemoglobin_g_dL	wbc_count
Min. : 3.0	Length:989	Min. :11.00	Min. : 2000
1st Qu.: 27.0	Class :character	1st Qu.:12.60	1st Qu.: 2600
Median : 40.0	Mode :character	Median :13.70	Median : 3200
Mean : 42.2		Mean :13.71	Mean : 4338
3rd Qu.: 55.0		3rd Qu.:15.00	3rd Qu.: 6200
Max. :120.0		Max. :25.00	Max. :10900
			NA's :24

```
differential_count    rbc_count    platelet_count
Min.      :0.0000    Min.      :0.0000    Min.      : 10000
1st Qu.:1.0000    1st Qu.:1.0000    1st Qu.: 46000
Median :1.0000    Median :1.0000    Median : 93000
Mean      :0.9393    Mean      :0.9383    Mean      :114702
3rd Qu.:1.0000    3rd Qu.:1.0000    3rd Qu.:162500
Max.      :1.0000    Max.      :1.0000    Max.      :500000
NA's      :16

platelet_distribution_width  dengue_label
Min.      : 1.00          Min.      :0.0000
1st Qu.: 14.00          1st Qu.:0.0000
Median : 17.80          Median :1.0000
Mean      : 22.85          Mean      :0.6512
3rd Qu.: 28.20          3rd Qu.:1.0000
Max.      :215.00          Max.      :1.0000
NA's      :19
```

descr(dados)

Descriptive Statistics

dados

N: 989

	age	dengue_label	differential_count	hemoglobin_g_dL
platelet_count				

Mean	42.20	0.65	0.94	13.71
114702.24				
Std.Dev	20.94	0.48	0.24	1.48
89421.77				
Min	3.00	0.00	0.00	11.00
10000.00				
Q1	27.00	0.00	1.00	12.60
46000.00				
Median	40.00	1.00	1.00	13.70
93000.00				
Q3	55.00	1.00	1.00	15.00
162500.00				
Max	120.00	1.00	1.00	25.00
500000.00				
MAD	20.76	0.00	0.00	1.78
87473.40				
IQR	28.00	1.00	0.00	2.40
116500.00				
CV	0.50	0.73	0.25	0.11
0.78				
Skewness	0.55	-0.63	-3.68	0.37
1.32				
SE.Skewness	0.08	0.08	0.08	0.08

0.08					
	Kurtosis	0.00	-1.60	11.52	2.06
1.83					
	N.Valid	989.00	989.00	989.00	989.00
973.00					
	N	989.00	989.00	989.00	989.00
989.00					
	Pct.Valid	100.00	100.00	100.00	100.00
98.38					

Table: Table continues below

	platelet_distribution_width	rbc_count	wbc_count
Mean	22.85	0.94	4338.03
Std.Dev	14.69	0.24	2344.53
Min	1.00	0.00	2000.00
Q1	14.00	1.00	2600.00
Median	17.80	1.00	3200.00
Q3	28.20	1.00	6200.00
Max	215.00	1.00	10900.00
MAD	7.12	0.00	1037.82
IQR	14.20	0.00	3600.00
CV	0.64	0.26	0.54
Skewness	5.23	-3.64	1.03
SE.Skewness	0.08	0.08	0.08
Kurtosis	58.80	11.25	-0.37
N.Valid	970.00	989.00	965.00
N	989.00	989.00	989.00
Pct.Valid	98.08	100.00	97.57

```
analyze_categorical <- function(column, label){
  ggplot(data.frame(column), aes(x=column)) +
    geom_bar(fill="lightblue") +
    labs(
      title=paste("Distribuição de", label),
      x=label,
      y="Frequência"
    ) +
    theme_minimal()
}

analyze_numerical <- function(column, columnLabel){

  Q0 <- min(column, na.rm = TRUE)
  Q1 <- as.numeric(quantile(column, 0.25, na.rm = TRUE))
  Q2 <- as.numeric(quantile(column, 0.50, na.rm = TRUE))
  Q3 <- as.numeric(quantile(column, 0.75, na.rm = TRUE))
```

```
Q4 <- as.numeric(quantile(column, 1.00, na.rm = TRUE))

IQR_val <- IQR(column, na.rm = TRUE)

mean_val <- mean(column, na.rm = TRUE)
sd_val <- sd(column, na.rm = TRUE)

# binwidth automático (Freedman-Diaconis)
n <- length(column)
binwidth <- 2 * IQR_val / (n^(1/3))

LI <- Q1 - 1.5 * IQR_val
LS <- Q3 + 1.5 * IQR_val

cat("Média:", mean_val, "\n")
cat("Mediana:", Q2, "\n")
cat("Desvio padrão:", sd_val, "\n")
cat("Q1:", Q1, "\n")
cat("Q3:", Q3, "\n")
cat("IQR:", IQR_val, "\n")

# Boxplot
box <- ggplot(data.frame(column), aes(x = "", y = column)) +
  geom_boxplot(fill = "lightblue") +
  geom_hline(yintercept = LI, color = "red", linetype = "dashed") +
  geom_hline(yintercept = LS, color = "blue", linetype = "dashed") +
  geom_hline(yintercept = Q0, color = "orange", linetype = "dashed") +
  geom_hline(yintercept = Q4, color = "orange", linetype = "dashed") +

  annotate("text", x = 1.2, y = Q0, label = "(0%)") +
  annotate("text", x = 1.2, y = Q1, label = paste("Q1 =", Q1)) +
  annotate("text", x = 1.2, y = Q2, label = paste("Q2 =", Q2)) +
  annotate("text", x = 1.2, y = Q3, label = paste("Q3 =", Q3)) +
  annotate("text", x = 1.2, y = Q4, label = "(100%)") +

  annotate("text", x = 1.2, y = LI, label = paste("Limite Inf:", round(LI, 2))) +
  annotate("text", x = 1.2, y = LS, label = paste("Limite Sup:", round(LS, 2))) +

  labs(title = paste("Boxplot -", columnLabel),
       y = columnLabel,
       x = "") +
  scale_y_continuous(labels = scales::comma)

# Histograma
hist <- ggplot(data.frame(column), aes(x = column)) +
  geom_histogram(binwidth = binwidth,
                aes(y = ..density..),
                fill = "lightblue",
                color = "black") +
  geom_density(color = "darkblue", size = 1) +
  geom_vline(xintercept = mean_val,
```

```

        color="red",
        linetype="dashed") +
geom_vline(xintercept=Q2,
           color="green",
           linetype="dashed") +
labs(title = paste("Histograma -", columnLabel),
     x = columnLabel,
     y = "Frequência")+
scale_x_continuous(labels = scales::comma)

qqplot <- ggqqplot(column)

shapiro_test <- shapiro.test(column)

print(box)
print(hist)
print(qqplot)
print(shapiro_test)

}

```

4.1 Análise de Colunas com Dados Nulos

As colunas com dados nulos foram poucas:

wbc_count: 24

platelet_count: 16

platelet_distribution_width: 19

```
colSums(is.na(dados))
```

age	gender
0	0
hemoglobin_g_dl	wbc_count
0	24
differential_count	rbc_count
0	0
platelet_count	platelet_distribution_width
16	19
dengue_label	
0	

4.2 Completude de dados

Os dados estão em sua maioria preenchidos a não ser pelos poucos dados faltantes das colunas acima.

Na minha visão, a completude impacta diretamente a análise exploratória, pois a presença de dados faltantes reduz a quantidade de informações disponíveis e pode comprometer os resultados.

Durante a análise, percebo que valores ausentes podem distorcer medidas estatísticas, dificultar a identificação de padrões e influenciar a interpretação dos dados.

platelet_count: 98%

platelet_distribution_width: 98%

wbc_count: 97%

age: 100%

hemoglobin_g_dl: 100%

differential_count: 100%

dengue_label: 100%

gender: 100%

rbc_count: 100%

```
colMeans(!is.na(dados))
```

age	gender
1.0000000	1.0000000
hemoglobin_g_dl	wbc_count
1.0000000	0.9757331
differential_count	rbc_count
1.0000000	1.0000000
platelet_count	platelet_distribution_width
0.9838220	0.9807887
dengue_label	
1.0000000	

4.3 Análise da Variável Age

A variável age apresenta alguns outliers acima do limite superior, incluindo um valor próximo de 120 anos. Apesar disso, média e mediana são próximas, indicando que os dados não são muito assimétricos.

```
analyze_numerical(dados$age, "Age")
```

Média: 42.19919


Mediana: 40


Desvio padrão: 20.94111


Q1: 27

Q3: 55

IQR: 28







Shapiro-Wilk normality test


```
data: column  
W = 0.97524, p-value = 6.081e-12
```

4.4 Análise da Variável Hemoglobin Level


A variável apresenta outliers acima do limite superior, com valores próximos de 25. Mesmo assim, média e mediana são próximas, indicando baixa assimetria.


```
analyze_numerical(dados$hemoglobin_g_dL, "Hemoglobin Level")
```

```
Média: 13.71294  
Mediana: 13.7  
Desvio padrão: 1.484111  
Q1: 12.6  
Q3: 15  
IQR: 2.4
```



Histograma - Hemoglobin Level





Shapiro-Wilk normality test

```
data: column  
W = 0.94491, p-value < 2.2e-16
```


4.5 Análise da Variável White Blood Cell Count

A variável apresenta outliers e dados faltantes. A diferença entre média e mediana indica leve assimetria, e a distribuição não parece normal.


```
analyze_numerical(dados$wbc_count, "White Blood Cell Count")
```


```
Média: 4338.031  
Mediana: 3200  
Desvio padrão: 2344.53  
Q1: 2600  
Q3: 6200  
IQR: 3600
```

Boxplot - White Blood Cell Count



Histograma - White Blood Cell Count





Shapiro-Wilk normality test

```
data: column  
W = 0.80885, p-value < 2.2e-16
```


4.6 Análise da Variável Platelet Count

A variável apresenta outliers e dados faltantes. A diferença entre média e mediana indica assimetria nos dados.


```
analyze_numerical(dados$platelet_count, "Platelet Count")
```


```
Média: 114702.2  
Mediana: 93000  
Desvio padrão: 89421.77  
Q1: 46000  
Q3: 162500  
IQR: 116500
```


Boxplot - Platelet Count



Histograma - Platelet Count





Shapiro-Wilk normality test

```
data: column  
W = 0.87991, p-value < 2.2e-16
```


4.7 Análise da Variável Variation in Platelet

A variável apresenta alguns outliers e dados faltantes, mas média e mediana próximas indicam baixa assimetria.


```
analyze_numerical(dados$platelet_distribution_width, "Variation in Platelet")
```


```
Média: 22.84887  
Mediana: 17.8  
Desvio padrão: 14.69287  
Q1: 14  
Q3: 28.2  
IQR: 14.2
```

Boxplot - Variation in Platelet



Histograma - Variation in Platelet





Shapiro-Wilk normality test


data: column

W = 0.65462, p-value < 2.2e-16

4.8 Análise da Variável Dengue

A variável mostra a distribuição dos casos com e sem dengue.


```
analyze_categorical(dados$dengue_label, "Target Variable")
```



4.9 Análise da Variável Gender

A variável apresenta a distribuição de gênero na base, podendo indicar possível desbalanceamento.

```
analyze_categorical(dados$gender, "Gender")
```




4.10 Análise da Variável Differential Count

A variável apresenta a distribuição das categorias relacionadas à contagem diferencial. A análise permite observar a frequência de cada grupo e identificar possíveis desbalanceamentos.

```
dados$differential_count = as.factor(dados$differential_count)
analyze_categorical(dados$differential_count, "Diff White Blood Cell Count")
```


Distribuição de Diff White Blood Cell Count




4.11 Análise da Variável Red Blood Cell Count

A variável apresenta a distribuição das categorias relacionadas à contagem de glóbulos vermelhos. É possível observar a proporção entre os grupos e verificar possíveis diferenças entre eles.

```
dados$rbc_count = as.factor(dados$rbc_count)
analyze_categorical(dados$rbc_count, "Red Blood Cell Count")
```

Distribuição de Red Blood Cell Count



5 Remoção de colunas categóricas

```
dados <- dados[, sapply(dados, is.numeric)]
```

6 Tratamento de Valores Nulos

Para tratar os dados faltantes, foi utilizada a técnica de imputação por meio do pacote MICE. O método utilizado foi o Predictive Mean Matching (PMM), que estima valores ausentes com base em valores observados semelhantes, preservando a distribuição dos dados. Foram realizadas 5 imputações (m=5). O parâmetro seed foi utilizado para garantir a reprodutibilidade dos resultados.

```
dados = complete(mice(dados, m=5, method="pmm", seed=123))
```

```
iter imp variable
1 1 wbc_count platelet_count platelet_distribution_width
1 2 wbc_count platelet_count platelet_distribution_width
1 3 wbc_count platelet_count platelet_distribution_width
1 4 wbc_count platelet_count platelet_distribution_width
1 5 wbc_count platelet_count platelet_distribution_width
```

```

2  1  wbc_count  platelet_count  platelet_distribution_width
2  2  wbc_count  platelet_count  platelet_distribution_width
2  3  wbc_count  platelet_count  platelet_distribution_width
2  4  wbc_count  platelet_count  platelet_distribution_width
2  5  wbc_count  platelet_count  platelet_distribution_width
3  1  wbc_count  platelet_count  platelet_distribution_width
3  2  wbc_count  platelet_count  platelet_distribution_width
3  3  wbc_count  platelet_count  platelet_distribution_width
3  4  wbc_count  platelet_count  platelet_distribution_width
3  5  wbc_count  platelet_count  platelet_distribution_width
4  1  wbc_count  platelet_count  platelet_distribution_width
4  2  wbc_count  platelet_count  platelet_distribution_width
4  3  wbc_count  platelet_count  platelet_distribution_width
4  4  wbc_count  platelet_count  platelet_distribution_width
4  5  wbc_count  platelet_count  platelet_distribution_width
5  1  wbc_count  platelet_count  platelet_distribution_width
5  2  wbc_count  platelet_count  platelet_distribution_width
5  3  wbc_count  platelet_count  platelet_distribution_width
5  4  wbc_count  platelet_count  platelet_distribution_width
5  5  wbc_count  platelet_count  platelet_distribution_width

```

Verificamos novamente se existem valores nulos

```
colSums(is.na(dados))
```

```

              age              hemoglobin_g_dl
              0              0
      wbc_count      platelet_count
              0              0
platelet_distribution_width      dengue_label
              0              0

```

7 Análise de pares

```

ggpairs(
  dados,


  lower = list(
    continuous = wrap("points") +
      scale_x_continuous(labels = scales::comma) +
      scale_y_continuous(labels = scales::comma)
  ),

  diag = list(
    continuous = wrap("densityDiag") +
      scale_x_continuous(labels = scales::comma)
  ),

  upper = list(

```

```
continuous = wrap("cor", size = 4)
)
)+ theme(axis.text = element_text())
```



A partir da análise visual da matriz de espalhamento as maiores correlações foram encontradas entre platelet_count e wbc_count, seguidas pelas relações com dengue_label e platelet_distribution_width, platelet_count e dengue_label, e platelet_count e platelet_distribution_width. As demais variáveis apresentam baixa correlação.

1. platelet_count × wbc_count → corr ≈ 0.749
2. platelet_distribution_width × dengue_label → corr ≈ -0.651
3. platelet_count × dengue_label → corr ≈ -0.577
4. platelet_count × platelet_distribution_width → corr ≈ 0.456

8 Resultado da Análise

8.1 Distribuições normais

Com base na análise, observei que as variáveis age e hemoglobin_g_dl apresentam comportamento mais próximo de uma distribuição normal, com menor assimetria. Por outro lado, as variáveis wbc_count,

platelet_count e platelet_distribution_width apresentam comportamento semelhante, com assimetria e presença de valores extremos, afastando-se da normalidade.

8.2 Histogramas

A partir da análise dos histogramas, observa-se que as variáveis age e hemoglobin_g_dl apresentam distribuição mais próxima da simétrica, com concentração de valores centrais e baixa assimetria. Por outro lado, as variáveis wbc_count, platelet_count e platelet_distribution_width apresentam comportamento semelhante, com assimetria à direita, indicando maior concentração de valores baixos e presença de cauda para valores elevados.

8.3 Justificativa dos Bins

O número de bins utilizado nos histogramas foi definido automaticamente com base na regra de Freedman-Diaconis, considerando a variabilidade e o tamanho da amostra. Essa abordagem foi aplicada de forma consistente para todas as variáveis, garantindo um equilíbrio entre detalhamento e clareza visual, independentemente das diferenças de escala e dispersão entre elas.

8.4 Shapiro-Wilk

O teste de Shapiro-Wilk indicou p-values menores que 0.05 para todas as variáveis, sugerindo não normalidade. No entanto, como a base de dados possui um número elevado de observações, o teste tende a ser muito sensível. Dessa forma, a análise foi complementada com histogramas e gráficos Q-Q, que indicaram que algumas variáveis apresentam comportamento próximo à normalidade, conforme descrito acima.

9 Dashboard Interativo

Foi desenvolvido um dashboard interativo utilizando o pacote Shiny, permitindo a seleção de variáveis numéricas da base de dados, o usuário pode escolher a variável a ser analisada, definir a cor do gráfico de linha e ajustar os limites dos eixos X e Y, possibilitando uma visualização dinâmica dos dados.

```
ui <- fluidPage(  
  
  titlePanel("Dashboard - Análise de Dados"),  
  
  sidebarLayout(  
    sidebarPanel(  
  
      selectInput("variavel", "Selecione a variável:",  
                  choices = names(dados)[sapply(dados, is.numeric)]),  
  
      selectInput("cor", "Escolha a cor:",  
                  choices = c("blue", "red", "green", "black")),
```

```
numericInput("xmin", "Limite inferior X:", value = 1),
numericInput("xmax", "Limite superior X:", value = 100),

numericInput("ymin", "Limite inferior Y:", value = 0),
numericInput("ymax", "Limite superior Y:", value = 100000)
),

mainPanel(
  plotOutput("grafico")
)
)
}

server <- function(input, output) {

  output$grafico <- renderPlot({

    var <- dados[[input$variavel]]

    df <- data.frame(x = 1:length(var), y = var)

    ggplot(df, aes(x = x, y = y)) +
      geom_line(color = input$cor) +
      xlim(input$xmin, input$xmax) +
      ylim(input$ymin, input$ymax) +
      labs(title = paste("Gráfico de", input$variavel),
           x = "Índice",
           y = input$variavel)
  })
}

shinyApp(ui = ui, server = server)
```

Shiny applications not supported in static R Markdown documents

Dashboard - Análise de Dados

Selecione a variável:

age ▼

Escolha a cor:

blue ▼

Limite inferior X:

1

Limite superior X:

100

Limite inferior Y:

0

Limite superior Y:

100

